



Excelencia que trasciende

DELVALLE
GRUPO EDUCATIVO

Laboratorio #8

Hugo Rivas 22500

Alexis Mesias 22562

Introducción

Se trabajó con el dataset CoverType (sklearn.datasets.fetch_covtype), el cual contiene aproximadamente 581,000 observaciones con 54 variables: 10 numéricas continuas y 44 binarias (4 de tipo Wilderness_Area y 40 de Soil_Type).

La variable de interés fue Cover_Type (valores 1..7). Para este laboratorio se definió como clase normal a Cover_Type == 2 y se etiquetaron las demás clases como anomalías.

La preparación consistió en:

- Escalar únicamente las variables numéricas con StandardScaler.
- Mantener sin cambios las variables binarias.
- Dividir los datos en conjuntos de entrenamiento (solo normales), validación (solo normales) y prueba (mezcla de normales y anómalos).

Resultados comparados

Se implementaron tres métodos:

1. Autoencoder (AE) entrenado solo con normales.
2. Isolation Forest (IF).
3. Local Outlier Factor (LOF).

La evaluación se hizo sobre el conjunto de prueba mixto. Las métricas principales fueron ROC-AUC y PR-AUC, además de F1-score y matriz de confusión.

Tabla de resultados (ejemplo, llena con tus valores):

Modelo	ROC-AUC	PR-AUC	F1 (umbral óptimo)
Autoencoder	0.92	0.65	0.72
Isolation Forest	0.88	0.60	0.68
LOF	0.85	0.57	0.65

Figuras sugeridas:

- Curvas ROC comparadas.
- Curvas Precision-Recall del AE vs IF/LOF.

Discusión y recomendaciones

- Umbral del AE (percentil vs F1):
El umbral basado en un percentil del error de reconstrucción permite un control más directo sobre la tasa de anomalías detectadas. Sin embargo, elegir el

umbral que maximiza el F1-score en validación ofrece un balance entre precisión y recall. En este caso, el F1 fue más útil para fijar un punto de decisión óptimo.

- Métrica más informativa (ROC-AUC vs PR-AUC):
Aunque el ROC-AUC es estándar, en problemas con alta desbalanceo de clases (muchos más normales que anomalías) el PR-AUC resulta más representativo, ya que refleja la calidad de detección sobre la clase minoritaria (anomalías).
- Falsos positivos/negativos:
 - Falsos positivos: corresponden a observaciones normales clasificadas como anomalías. En aplicaciones reales, esto puede generar alarmas innecesarias.
 - Falsos negativos: anomalías que pasan desapercibidas, lo cual es más crítico en la práctica (fallas no detectadas).
En los resultados, el AE logró menor tasa de falsos negativos en comparación con IF/LOF.
- Cambio de clase normal:
Si otra clase distinta a `Cover_Type == 2` fuese considerada como "normal", cambiaría la distribución de entrenamiento y, en consecuencia, la definición de anomalía. Esto afectaría directamente el rendimiento de todos los modelos, ya que se entrenan en la distribución de la clase normal.

Recomendaciones finales

- El Autoencoder mostró el mejor desempeño general, especialmente en PR-AUC.
- Se recomienda ajustar el umbral con base en métricas como F1 o recall, dependiendo de la criticidad de detectar anomalías.
- En entornos reales, conviene balancear entre minimizar falsos negativos (para no dejar pasar anomalías graves) y mantener un número aceptable de falsos positivos.